

流程节点参数配置

1. 问题改写配置

```
{
  "llm_config": {
    "provider": "vLLM", // 大模型服务提供商
    "model": "Qwen3-32B", // 使用的大模型名称
    "base_url": "http://10.16.6.191:3000/v1", // 大模型API基础地址
    "api_key": "sk-mgzgXlYPgzBiBulID157B1A63cB34a118d9342575d187e4e", // 访问大模型的API密钥
    "temperature": 0.2, // 温度参数，控制生成结果的随机性
    "max_tokens": 8192, // 最大token数量限制
    "top_p": 0.9, // 核采样参数，控制生成结果的多样性
    "frequency_penalty": 0.1, // 频率惩罚参数
    "presence_penalty": 0.2 // 存在惩罚参数
  },
  "vdb_config": {
    "db_name": "tenant",
    "collection_name": "testa"
  }
}
```

2. 信息推理配置

```
{
  "retrieval_type": "hybrid", // 召回类型，支持混合召回等策略
  "score_threshold": 0.5, // 向量相似度阈值，低于该值的结果将被过滤
  "top_k": 30, // 返回最相关的前K个结果
}
```

3. SQL生成配置

```
{
  "m_schema": "m_schema", // 数据库表结构信息
  "llm_config": {
    "provider": "vLLM", // 大模型服务提供商
    "model": "Qwen3-32B", // 使用的大模型名称
    "base_url": "http://10.16.6.191:3000/v1", // 大模型API基础地址
    "api_key": "sk-mgzgXlYPgzBiBulID157B1A63cB34a118d9342575d187e4e", // 访问大模型的API密钥
    "temperature": 0.2, // 温度参数，控制生成结果的随机性
    "max_tokens": 8192, // 最大token数量限制
    "top_p": 0.9, // 核采样参数，控制生成结果的多样性
    "frequency_penalty": 0.1, // 频率惩罚参数
    "presence_penalty": 0.2 // 存在惩罚参数
  },
  "dialect": "mysql", // 数据库类型，如MySQL、PostgreSQL等
  "sql_gen_template": "提示词模版" // 提示词模板，用于指导SQL生成逻辑
}
```

4. SQL修复配置

```
{
  "m_schema": "m_schema", // 数据库表结构信息
  "llm_config": {
    "provider": "vLLM", // 大模型服务提供商
    "model": "Qwen3-32B", // 使用的大模型名称
    "base_url": "http://10.16.6.191:3000/v1", // 大模型API基础地址
    "api_key": "sk-mgzgXlYPgzBiBulID157B1A63cB34a118d9342575d187e4e", // 访问大模型的API密钥
    "temperature": 0.2, // 温度参数, 控制生成结果的随机性
    "max_tokens": 8192, // 最大token数量限制
    "top_p": 0.9, // 核采样参数, 控制生成结果的多样性
    "frequency_penalty": 0.1, // 频率惩罚参数
    "presence_penalty": 0.2 // 存在惩罚参数
  },
  "sql_query": "出错的SQL语句", // 出错的SQL语句
  "error_info": "错误信息", // 错误信息
  "repair_strategy": "step_by_step", // 修复策略, 如逐步修复、完全重写等
  "max_repair_attempts": 3 // 最大修复尝试次数
}
```

5. 图表生成配置

```
{
  "sql_query": "SQL查询语句", // SQL查询语句
  "llm_config": {
    "provider": "vLLM", // 大模型服务提供商
    "model": "Qwen3-32B", // 使用的大模型名称
    "base_url": "http://10.16.6.191:3000/v1", // 大模型API基础地址
    "api_key": "sk-mgzgXlYPgzBiBulID157B1A63cB34a118d9342575d187e4e", // 访问大模型的API密钥
    "temperature": 0.2, // 温度参数, 控制生成结果的随机性
    "max_tokens": 8192, // 最大token数量限制
    "top_p": 0.9, // 核采样参数, 控制生成结果的多样性
    "frequency_penalty": 0.1, // 频率惩罚参数
    "presence_penalty": 0.2 // 存在惩罚参数
  },
  "records": [
    {
      "product_name": "iPhone 15 Pro",
      "current_inventory": 8
    }
  ]
}
```